KMP详解

有这样一个问题:

- KMP详解
 - 。 1 两种字符串匹配思路
 - 1.1 暴力思路 O(m * n)
 - 1.2 KMP思路 O(m + n)
 - 2 概念补充
 - 2.1 模式串和模板串
 - 2.2 前缀后缀
 - 2.3 next数组
 - 。 3 代码实现
 - 3.1 next数组的应用
 - 3.2 next数组的初始化
 - 3.3 总代码

给定一个字符串(模式串S): "BBC ABCDAB ABCDABCDABDE" 我想知道其中是否包含(模板串P) "ABCDABD" ?

1 两种字符串匹配思路

1.1 暴力思路 O(m * n)

想象两把尺子, s 是上面的长尺, p 是下面的短尺, 最开始两个尺子左端对齐, 下面的短尺从左到右一位一位移动, 直到匹配成功。

比如: 当下面的尺子对齐了上面的 ABCDAB, 但是 D 对应的是空格,这时匹配失败,只能往右再一位一位移动

暴力实现的代码可以参考如下:

1.2 KMP思路 O(m + n)

Knuth、Morris、Pratt三个学者提出这样一种方法:就这个例子而言,当 D 对应的是空格时,我们并没有前功尽弃,因为我们已知 D 前面的 ABCDAB 是已经正确匹配的,同时我们发现正确匹配的字符串前后两端都有 AB (ABCDAB),那么我们可以直接向后移动 4 位,继续去匹配空格,观察能否匹配成功,即:

• 初始

BBC ABCDAB ABCDABCDABDE XXX AB CD AB D

• 向后移动4位

BBC ABCDAB ABCDABCDABDE
XXX XXXX AB CD AB D

• 注: X代表检查过的

如果空格匹配成功则继续,匹配失败的话可以再观察是否有类似"回文"1的形式,如果有的话可以一次移动多位,如果没有只能一位一位移了。(实际上还剩下的AB已经不具备跳着移动的条件了,如果仍然无法匹配,只能全部移过去从头开始了)

注1: "类似"的含义是: ABAB不是回文形式, ABABA是回文形式, 两者都可以跳着走。

我们再给一个例子来感受KMP:

模式串S: ababaeaba 模板串P: ababacd

> ababa eaba ababa cd

'c' 无法与 'e' 匹配, 观察到 "ababa" 的头是 "aba", 尾也是 "aba", 那么可以直接移2位

ab *aba* eaba xx *aba* bacd

'b'仍然无法与'e'匹配,观察到"aba"的头是"a",尾也是"a",那么可以直接移2位

abab a eaba xxxx a babacd

'b' 无法与 'e' 匹配 (紧跟亮色后面的) ,只剩a也不能跳着走了,这样就只能从e开始重新来了。如果是暴力的话,第一次匹配不到e,可能就是这样的结果: (一位一位移动看是否能匹配)

- ababaeaba
- xababacd
- xxababacd

• ...

2 概念补充

2.1 模式串和模板串

s[]是模式串,即比较长的字符串。

p[]是模板串,即比较短的字符串。(这样可能不严谨)

2.2 前缀后缀

"非平凡前缀": 指除了最后一个字符以外,一个字符串的全部头部组合。

"非平凡后缀": 指除了第一个字符以外, 一个字符串的全部尾部组合。

以下均简称为前/后缀。

举例: P = abcab, 假设下标从1开始, 分别对应1、2、3、4、5

下标	前缀	后缀
1	空	空
2	{ a }	{ b }
3	{ a, ab }	{ c, bc }
4	{ a, ab, abc }	{ a, ca, bca }
5	{ a, ab, abc, abca }	{ b, ab, cab, bcab }

2.3 next数组

在上面的例子中,我们每一次应该向右直接移动多少位是通过next数组得到的,而 next 数组是经过预处理得到的。

简单的来讲, next 数组可以这样通俗地描述:

next[i]: 以i为终点的后缀和从1开始的前缀相等,且长度最长。数组中存放的是这个前缀的最后一个元素的下标。(因为这样才能拼接过去)

```
// 伪代码形式
next[i] = j;
p[1, j] = p[i - j + 1, i]
```

还是刚刚那个: P = abcab

下标i	前缀	后缀	next[i]
1	空	空	0
2	{a}	{ b }	0
3	{ a, ab }	{ c, bc }	0
4	{ <mark>a</mark> , ab, abc }	{ <mark>a</mark> , ca, bca }	1
5	{ a, <mark>ab</mark> , abc, abca }	{ b, <mark>ab</mark> , cab, bcab }	2

eg.对5来说, next[5] = 2的含义就是: p[1 ~ 2] = p[4 ~ 5]

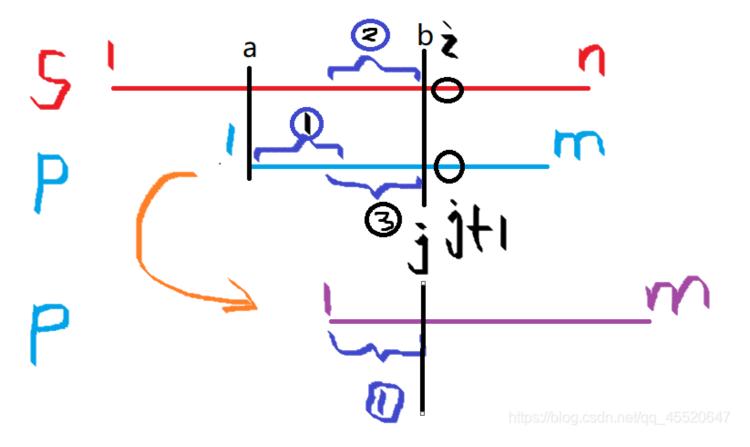
3 代码实现

3.1 next数组的应用

有了next数组,我们每次匹配不成功时,就可以直接得出下一个跳向哪个位置,这一操作可以直接由j=next[j]来完成。

插句题外话,在 y 总眼里,这是 j 的回退,其实 j 每次回退,都是 P 串在跳跃行进匹配的过程。假设我们已经有了 next 数组,那么 kmp 匹配的过程可以用代码表示如下:

贴一张y总上课讲的抽象图: (配合上面代码)



3.2 next数组的初始化

先给一个例子,便于下面算法的模拟,顺便看看对next数组是否理解了:

P = ababa , 则: (始终记住KMP算法中下标我们都从1开始)

next[i]	初始化	依据
1	0	空
2	0	空
3	1	а
4	2	ab
5	3	aba

next数组的初始化的本质就是自己和自己匹配。

一定要想清楚在kmp匹配过程中,P字符串的 j 到底意味着什么: j 的作用就是下一次 P 字符串的开始匹配点(的前一个)。

通俗的讲,j 就是在P串中能匹配到哪,记录每一个能匹配到哪的位置就是next的初始化过程。 好难描述我脑海中的动图,希望以后的我能看懂……

最开始

j = 0 ababa

i = 2 baba 无法匹配到,所以ne[2] = 0

- i = 3 aba 匹配到了, j = 1, 所以ne[3] = 1
- i = 4 ba 匹配到了, j = 2, 所以ne[4] = 2
- i = 5 a 匹配到了, j = 3, 所以ne[5] = 3
- 如果匹配不到的话, 也不用一步一步挪, 直接用已经有的ne[i], 匹配的会更快

代码写出来和3.1几乎一样,毕竟都是匹配的过程。

```
for(int i = 2, j = 0; i <= n; i ++){
    while(j && p[i] != p[j + 1]) j = ne[j];
    if(p[i] == p[j + 1]) j ++;
    ne[i] = j;
}</pre>
```

3.3 总代码

总结: KMP算法可以实现字符串的快速匹配问题

题目链接: KMP匹配字符串

```
#include<iostream>
```

```
using namespace std;
const int N = 100010;
const int M = 1000010;
char p[N], s[M];
int ne[N];
int main(){
   int m, n;
   cin >> n >> p + 1 >> m >> s + 1; // 保证下标从1开始 (优雅来自于细节啊)
   // 求next
   for(int i = 2, j = 0; i <= n; i ++){
       while(j && p[i] != p[j + 1]) j = ne[j];
       if(p[i] == p[j + 1]) j ++;
       ne[i] = j;
   }
   // kmp匹配
   for(int i = 1, j = 0; i <= m; i ++){
       while(j && s[i] != p[j+1]) j = ne[j]; // 当j没有回退起点 且 当前的S[i]无法匹配时
       if(s[i] == p[j + 1]) j ++;
       if(j == n){
              printf("%d ", i - n);
              j = ne[j]; // 继续寻找下一个匹配串
       }
   }
   return 0;
}
```